

(a) Direct scheduling

(b) Hybrid (LLM to MILP)

Failure rate

1.0

0.8

0.6

0.4

0.2

0.0

GPT-4o-mini

·

1.00

0.22

·

1.00

·

·

0.67

·

0.17

·

0.67

Gemini 2.5 Flash

·

·

·

0.17

·

·

·

·

·

·

·

·

Claude Sonnet 4.6

·

·

·

·

·

·

·

·

·

·

·

·

Llama-3.3 70B

0.42

0.33

0.67

1.00

1.00

0.67

·

·

0.11

·

1.00

·

Qwen-3 32B

0.08

·

·

0.33

1.00

0.67

0.25

·

0.89

·

1.00

·

S1

S2

S3

S4

S5

S6

S1

S2

S3

S4

S5

S6

*S1 deadline · S2 power cap · S3 irregular calendar · S4 infeasible · S5 instruction conflict · S6 tool failure*